Cheatsheet AZ-305 — 15 · Plataformas de datos, analítica e integración

1. Mapa de servicios de datos

Servicio	Categoría	Para qué	Señal
Azure Data Factory (ADF)	Integración / ETL-ELT	Pipelines low-code, 90+ conectores, mapping data flows (Spark sin código), Self-hosted IR (on-prem), Azure-SSIS IR	"batch ETL", "low-code", "on-prem sources", "SSIS"
Synapse pipelines	Integración	ADF integrado en Synapse	Mismo que ADF dentro de Synapse
Synapse Analytics	Plataforma analítica unificada	Dedicated SQL pools (warehouse MPP), serverless SQL (consultar el lake), Spark pools, pipelines, Synapse Link	"data warehouse", "query the lake directly"
Microsoft Fabric	SaaS analítico unificado	Lakehouse, Warehouse, Data Factory, Real-Time, Power BI con OneLake y **Direct Lake**	"single SaaS platform", "Power BI without import"
Azure Databricks	Spark gestionado	Data engineering, ML, Delta Lake; Unity Catalog / Credential Passthrough	"Spark", "notebooks", "ML at scale"
Azure Stream Analytics	Streaming en tiempo real	Consultas **SQL** sobre flujos (Event Hubs, IoT Hub, Blob) con ventanas temporales; salidas a SQL, Cosmos, Power BI, Functions…	"real-time", "windowing", "SQL-like over streams", "Power BI dashboard live"
Azure Data Explorer (ADX / Kusto)	Analítica de logs y series temporales	Ingesta masiva, consultas **KQL** interactivas sobre TB en segundos; base de Log Analytics y Sentinel	"telemetry analytics", "time series", "interactive ad-hoc over billions of rows"
Event Hubs / IoT Hub	Ingesta	Ver abajo	
Data Lake Storage Gen2	Almacenamiento de lake	Hierarchical namespace, POSIX ACLs, Hadoop	"lake", "Hadoop", "directories by date"
Cosmos DB	NoSQL global	Ver cheatsheet 09	
Azure SQL / Hyperscale	Relacional	Ver cheatsheet 09	
Azure Cache for Redis	Caché	Session state, caché de lectura	"near the app"
Microsoft Purview	Gobernanza de datos	Catálogo, clasificación, linaje, glosario	"discover and classify sensitive data"
Azure Data Share	Compartición	Snapshots a otras organizaciones	"partner", "restricted access to snapshots"
Azure AI Search	Búsqueda	Índices full-text, vectorial	"search across documents"

2. Data Factory: piezas que caen

Pieza	Detalle
Pipeline / activities	Copy, Data Flow, Lookup, ForEach, Execute SSIS, Databricks notebook…
Integration Runtime (IR)	**Azure IR** (cloud, gestionado) · **Self-hosted IR** (instalado on-prem/VM para orígenes privados; ex Data Management Gateway; HA con varios nodos) · **Azure-SSIS IR** (ejecuta paquetes SSIS; SSISDB en Azure SQL DB o MI)
Mapping data flows	Transformaciones visuales ejecutadas en Spark gestionado
Triggers	Schedule · Tumbling window (ventanas sin solapamiento, reintentos, dependencias) · Event-based (Blob created/deleted vía Event Grid) · Manual
Linked services / datasets	Conexiones y estructuras
Managed VNet + Private Endpoints	Azure IR dentro de red gestionada para acceder a PaaS privados
CI/CD	Git integration (Azure Repos / GitHub), ARM export
Monitorización	Azure Monitor, alertas por fallo de pipeline

- ADF **mueve y transforma**; **no** comparte datos con terceros (Data Share) ni analiza en tiempo real (Stream Analytics).

3. Streaming: quién hace qué

Etapa	Servicio
Ingesta de telemetría de dispositivos (bidireccional, device management, DPS)	**IoT Hub**
Ingesta de eventos de apps / logs (unidireccional, alto volumen, Kafka)	**Event Hubs**
Captura automática a Storage/ADLS por fecha	**Event Hubs Capture**
Procesado en tiempo real con SQL y ventanas	**Stream Analytics**
Procesado en tiempo real con código / Spark	**Functions** (por evento) / **Databricks / Synapse Spark** Structured Streaming
Analítica interactiva sobre lo ingerido	**Data Explorer**
Dashboard en vivo	**Power BI** (streaming dataset desde Stream Analytics)
Almacenar resultados	SQL, Cosmos DB, ADLS
Edge	**IoT Edge** (módulos en el dispositivo; Stream Analytics on IoT Edge)

- "IoT devices" + "device provisioning / twins / commands to devices" → **IoT Hub**; solo telemetría entrante masiva sin gestión → **Event Hubs** es más barato.
- "hot path" (segundos) → Stream Analytics; "cold path" (batch) → ADF/Synapse; "warm path" (minutos, interactivo) → Data Explorer.

4. Warehousing y lakehouse: elegir el motor

Necesidad	Motor
Warehouse relacional MPP, pocas consultas pesadas	Synapse **dedicated SQL pool** (≤128 concurrentes)
Warehouse relacional, **alta concurrencia (>128)**, hasta 100 TB	**Azure SQL Hyperscale**
Consultar archivos del lake sin cargar (pago por TB escaneado)	Synapse **serverless SQL**
Transformaciones Spark, Delta Lake, ML	Databricks / Synapse Spark / Fabric
Analítica sobre Cosmos DB sin ETL	**Synapse Link** (analytical store)
Analítica sobre Azure SQL sin ETL	Synapse Link for SQL
Logs / series temporales a escala	Data Explorer
Power BI sobre el lake sin importar	Fabric **Direct Lake**
Capacidad Fabric saturada	Escalar SKU (F4 → F8…), optimizar refrescos, gobernanza de workspaces

5. Purview (gobernanza de datos)

Función	Qué hace
Data Map	Escanea orígenes (Azure, on-prem vía self-hosted IR, AWS, Power BI) y construye el mapa
Data Catalog	Búsqueda de activos, glosario de negocio, propietarios
Clasificación	Detecta datos sensibles (PII, tarjetas) con reglas integradas y custom
Lineage	Origen → transformaciones (ADF, Synapse) → informes
Data Estate Insights	Métricas de cobertura y sensibilidad
Señal	"catalog", "classify sensitive data across the estate", "lineage", "data governance"

- Purview ≠ Azure Policy (gobierna recursos, no datos) ≠ Defender (seguridad) ≠ Data Share.

6. Databricks: puntos de examen

Tema	Regla
Identidad de usuario hasta ADLS (ACLs por carpeta)	**Credential Passthrough** (Personal/Single User compute) o **Unity Catalog** con external locations
Apps on-prem que llaman al workspace, rotación de personal	**Service principal** (no PAT, no managed identity fuera de Azure)
Secretos	Secret scopes respaldados por Key Vault
Rendimiento de consultas	Photon (motor), no seguridad
Red privada	VNet injection, Private Link
Tiers	Standard vs Premium (RBAC granular, credential passthrough, audit logs)

7. Árbol de decisión

```
¿Qué hago con los datos?
├─ Mover / transformar en lote, low-code ..... Data Factory (Self-hosted IR si on-prem)
├─ Procesar un flujo en tiempo real con SQL ..... Stream Analytics
├─ Procesar un flujo con código ..... Functions / Spark streaming
├─ Ingerir de dispositivos con gestión ..... IoT Hub
├─ Ingerir eventos masivos de apps ..... Event Hubs
├─ Consultar logs/telemetría interactivamente ..... Data Explorer
├─ Warehouse relacional MPP ..... Synapse dedicated pool (Hyperscale si >128 concurrentes)
├─ Consultar el lake sin cargar ..... Synapse serverless
├─ Spark / ML ..... Databricks / Synapse Spark
├─ Analítica sobre Cosmos DB sin ETL ..... Synapse Link
├─ Catalogar y clasificar datos ..... Purview
├─ Compartir con un partner ..... Data Share
└─ Plataforma SaaS única con Power BI ..... Fabric
```

8. Señales → respuesta

Enunciado	Respuesta
"low-code batch ETL", "mapping data flows"	Data Factory
"run existing SSIS packages"	Azure-SSIS IR
"ADF must read SQL Server on-prem"	Self-hosted Integration Runtime
"real-time aggregation with time windows, SQL syntax"	Stream Analytics
"device twins, provisioning, cloud-to-device"	IoT Hub

Enunciado	Respuesta
"interactive queries over billions of log rows"	Data Explorer
"query JSON files in the lake directly"	Synapse serverless SQL
"50 TB relational + 300 concurrent reads"	Hyperscale
"near real-time analytics on Cosmos DB"	Synapse Link
"user identity enforces folder ACLs in Databricks"	Credential Passthrough
"classify sensitive data across sources, lineage"	Purview
"give Fabrikam restricted access to snapshots"	Data Share
"reduce table scans in Table Storage"	Migrar a Cosmos DB con partition key adecuada

9. Errores a evitar

1. Stream Analytics para ETL batch → ADF.
2. Event Hubs cuando piden gestión de dispositivos → IoT Hub.
3. Synapse dedicated pool con alta concurrencia → Hyperscale.
4. Purview para gobernar recursos → Policy.
5. Data Factory para compartir con terceros → Data Share.
6. PAT en Databricks con rotación de personal → service principal.